

博士研究計畫

史哲政 Zhe-Zheng Shi

題目：從可稽核紀錄到可驗證責任歸屬：學習致動系統的權限邊界形式化與稽核軌跡驗證

From Auditable Records to Verifiable Accountability: Formalising Authority Bounds and Verifying Audit Trails in Learning-Enabled Actuation Systems

研究方向：**Trustworthy and Auditable Multimodal Agents for Safety-Critical Autonomous Systems**

一、研究背景與文獻缺口

多模態基礎模型正進入安全關鍵的致動迴路，例如自動駕駛、機器人與公共安全監控。這類系統一旦判斷錯誤，監理機關、第三方稽核方與法庭需要的不是事後的說明，而是可被獨立驗證的證據：這份推理紀錄是否就是當下實際驅動控制的依據。

近年視覺語言模型應用於自動駕駛之研究，例如 DriveLM [1]、DriveVLM [2] 與 LMDrive [3]，普遍將模型產生之語言推理視為可解釋性之來源。然而可解釋 AI 之綜述指出，事後產生之解釋多缺乏驗證機制 [4]；忠實性研究更顯示，語言模型之推理鏈可能與其實際決策依據不一致 [5]、[6]。安全保障與紀錄保全兩個研究脈絡各自解決了問題的一部分，卻未處理推理與致動之間的連結：

研究脈絡	能保證	無法保證
語言推理之自駕模型 [1]–[3]	產生人類可讀之理由	理由即為實際決策依據 [5]、[6]
執行期保障、安全遮蔽、形式化安全模型 [7]–[9]	致動落在安全包絡內	語義推理對致動的影響範圍可界定、可追溯
防竄改稽核紀錄、機器人事件紀錄器 [13]–[15]	紀錄事後未被竄改	紀錄內容與當下致動之因果關係

歐盟人工智慧法對高風險系統要求自動紀錄與人為監督 [16]，但技術上如何使紀錄同時具備完整、不可否認且可驗證因果，仍為開放問題。

本人碩士階段的基礎。碩士論文提出嚴格梯度解耦之雙過程架構：System 1 負責確定性幾何控制，System 2 產出四層次圖視覺問答推理鏈作為稽核紀錄，兩者訓練時完全分離，推論時僅透過非對稱因果融合橋耦合。於 CARLA 閉環五條路線共 5,000 m、五個隨機種子之評估中，達成完整路線完成與零碰撞，語義-控制一致性 $97.35 \pm 1.14\%$ 、因果影響率 (System 2 對控制鏈之介入頻率) $75.60 \pm 2.58\%$ ，速度代價約 6%。碩士研究亦證實開環指標無法預測閉環可行性 (亦見 [18])，因此本計畫之所有性質皆在閉環中驗證。

但這些仍是相關性證據。這正是本計畫要跨越的門檻。

二、研究問題

一段稽核紀錄若要承擔責任歸屬，須同時滿足三項條件，而就我所知，現有研究尚未同時達成：

	條件	碩士階段現況	本計畫對策
C1	完整性 ：無未記錄之致動旁路	未處理	資訊流分析、架構層強制
C2	不可否認性 ：紀錄不可竄改且可證明為當下所用	未處理	雜湊鍵、可信執行環境
C3	反事實可檢驗 ：可重放驗證因果	介入頻率，非反事實必要性	確定性重放、反事實介入

核心研究問題：能否設計一種學習致動系統之架構與稽核協定，使「模型推理對致動的影響」成為可形式化驗證的性質，而非統計上的觀察？具體分為四個子問題：

- **RQ1** 雙過程架構之權限邊界，能否形式化為安全不變量，並以構造方式保證不被違反？
- **RQ2** 能否證明所有到達致動器之訊號皆經過稽核通道？(C1)
- **RQ3** 能否在即時控制預算內，產生不可竄改且可證明為當下所用之稽核軌跡？(C2)
- **RQ4** 稽核紀錄中的推理，是否在干預意義上真實影響致動？此性質能否跨越模擬器與應用場域？(C3)

三、研究方法

研究工作 1：權限邊界形式化 (RQ1)

- **起點**：碩士之融合橋已以工程方式實作有界權限：System 1 於高曲率轉彎、方向衝突與 System 2 失效等安全關鍵情境保有完整橫向控制權；System 2 僅能透過有界否決降低速度目標，不能提高。
- **方法**：以信號時序邏輯 (STL) [10] 將上述規則表述為規格，例如「任何時刻之速度指令不高於 System 1 之速度目標」、「安全關鍵情境下之轉向指令等於 System 1 之輸出」。融合橋之判斷邏輯規模有限，可以 SMT 求解器 [12] 對任意 System 2 輸出窮舉驗證其滿足規格；閉環執行時以 STL 穩健度 [11] 進行線上監控。
- **驗證**：對 System 2 注入隨機、對抗性與失效輸出，並與執行期保障架構 [7]、安全遮蔽 [8] 之做法對照。
- **判準**：規格違反次數為零，並報告穩健度分布，指出最接近違反之情境。
- **意義**：稽核對象因此由「模型行為」(不可窮舉) 轉為「規格是否被違反」(可判定)。

研究工作 2：致動完整性 (RQ2)

- **起點**：碩士原型之控制堆疊，包含感測輸入、雙系統推論、融合橋與車輛控制輸出。
- **方法**：建立控制軟體之資訊流圖，找出所有能影響致動器之通道；在架構上設置單一致動閘道，僅接受已登錄於稽核軌跡之指令，使繞過稽核之訊號無法到達致動器。
- **驗證**：以故障注入植入多類旁路，包括直接寫入車輛控制、繞過融合橋、重放舊指令，量測偵測率與正常運行下之誤報率。
- **判準**：植入旁路之偵測率 100%，正常運行誤報為零。

研究工作 3：不可否認之稽核軌跡 (RQ3)

- **方法**：每個控制週期將感測影格雜湊值、System 2 推理輸出、融合後指令與時間戳組成一筆紀錄，以雜湊鍵串接，並定期對 Merkle 樹根簽章 [13]、[14]；簽章金鑰置於可信執行環境，使紀錄即使由系統擁有者事後修改亦可被偵測。

- **驗證**：竄改測試（刪除、修改、插入、重排紀錄）；效能預算以模擬器 30 Hz 控制週期為基準，量測稽核層之每週期延遲與每小時儲存量。
- **判準**：竄改偵測率 100%；加入稽核層後閉環之路線完成與碰撞結果不變，每週期額外延遲以控制週期之 10% 為設計上限。
- **備案**：若硬體信任根受限於實驗設備，改採軟體層金鑰搭配外部時間戳，並輔以形式化威脅模型分析，不影響其他研究工作。

研究工作 4：反事實驗證與跨域效度（RQ4）

- **起點**：碩士之因果影響率 $75.60 \pm 2.58\%$ 衡量的是 System 2 對控制鏈之介入頻率，其中 72.43 個百分點來自模板傳播之語義速度調節，即時 VLM 推理僅占 1.69%；碩士論文已明確指出，此指標並非 System 2 對控制決策之**反事實必要性**，嚴格定義下之數值將更小。本研究即以反事實必要性重新定義並逐筆量測。
- **方法**：以 CARLA 同步模式與固定隨機種子建立可重現之重放，先量化重放本身之殘餘變異；再於單一決策時點進行干預 [17]：替換 System 2 之輸出，或遮蔽紀錄中所引用之場景要素（例如推理提及之行人），檢驗致動之改變是否與紀錄所述理由一致。
- **跨域**：延伸碩士之跨版本配對方法（CARLA 0.10.0 與 0.9.15，150 場配對閉環），擴展至不同模擬器與至少一個非自駕致動場域；碩士論文明確留下的兩個缺口，即跨域遷移與視覺紋理域偏移，在此一併處理。
- **判準**：報告紀錄忠實率，即紀錄所述理由經干預確認為致動原因之比例，並比較不同場域間之差異。

評估總覽

條件	指標	判準
權限邊界	STL 規格違反次數、穩健度分布	違反為零
完整性	植入旁路偵測率、正常運行誤報率	100% / 0
不可否認性	竄改偵測率、每週期延遲、儲存成本	100% / 延遲不超過控制週期 10%
反事實可檢驗	重放變異、紀錄忠實率、跨域差異	重放變異小於干預效應

四、預期貢獻

1. **理論**：學習致動系統中權限邊界的形式化框架，將 AI 模組權限從訓練期望轉為可驗證不變量。
2. **方法**：可稽核性三條件（完整性、不可否認性、反事實可檢驗）之評估協定與對應指標。
3. **系統**：具備可驗證稽核軌跡的閉環自駕原型，延續碩士階段自建之閉環基準。
4. **治理**：對應高風險 AI 系統可追溯性與人為監督要求之技術落實路徑，可供監理與產業參考。

五、可行性

- **已有基礎**：碩士論文與 IEEE Access、CACS 稿件已建立完整的閉環實驗平台、多種子評估流程（ $n = 5$ ）、跨版本配對診斷方法與自建基準，毋須重建。
- **跨域能力**：ISO 27001 Lead Auditor 與近二十年安全關鍵系統交付經驗，使密碼學稽核層與監理對接有實務基礎。
- **研究能量**：碩士學位於在職期間兩年內完成，修畢 26 學分、學業平均 93.0 分，並完成學位論文、會議論文投稿與期刊稿件。
- **風險與備案**：研究工作 3 若受限於硬體信任根之實驗設備，退為軟體層承諾機制與形式化威脅模型分析，不影響其餘研究工作。

六、時程 (五年)

年度	主要工作	預期產出
第一年	研究工作 1、修課	會議論文 1 篇，形式化框架
第二年	研究工作 2、資格考核	期刊論文 1 篇
第三年	研究工作 3	期刊或國際會議論文 1 篇，原型系統
第四年	研究工作 4	期刊論文 1 篇
第五年	整合與博士論文	博士論文

參考文獻

1. C. Sima et al., "DriveLM: Driving with Graph Visual Question Answering," Proc. ECCV, 2025.
2. X. Tian et al., "DriveVLM: The Convergence of Autonomous Driving and Large Vision-Language Models," Proc. CoRL, 2025.
3. H. Shao et al., "LMDrive: Closed-Loop End-to-End Driving with Large Language Models," Proc. CVPR, 2024.
4. S. Atakishiyev et al., "Explainable Artificial Intelligence for Autonomous Driving: A Comprehensive Overview and Field Guide for Future Research Directions," IEEE Access, vol. 12, 2024.
5. A. Jacovi and Y. Goldberg, "Towards Faithfully Interpretable NLP Systems: How Should We Define and Evaluate Faithfulness?," Proc. ACL, 2020.
6. M. Turpin et al., "Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting," Proc. NeurIPS, 2023.
7. L. Sha, "Using Simplicity to Control Complexity," IEEE Software, vol. 18, no. 4, 2001.
8. M. Alshiekh et al., "Safe Reinforcement Learning via Shielding," Proc. AAAI, 2018.
9. S. Shalev-Shwartz, S. Shammah, and A. Shashua, "On a Formal Model of Safe and Scalable Self-Driving Cars," arXiv:1708.06374, 2017.
10. O. Maler and D. Nickovic, "Monitoring Temporal Properties of Continuous Signals," Proc. FORMATS/FTRTFT, 2004.
11. A. Donzé and O. Maler, "Robust Satisfaction of Temporal Logic over Real-Valued Signals," Proc. FORMATS, 2010.
12. L. de Moura and N. Bjørner, "Z3: An Efficient SMT Solver," Proc. TACAS, 2008.
13. B. Schneier and J. Kelsey, "Secure Audit Logs to Support Computer Forensics," ACM Trans. Inf. Syst. Secur., vol. 2, no. 2, 1999.
14. S. A. Crosby and D. S. Wallach, "Efficient Data Structures for Tamper-Evident Logging," Proc. USENIX Security, 2009.
15. A. F. T. Winfield and M. Jirotko, "The Case for an Ethical Black Box," Proc. TAROS, 2017.
16. Regulation (EU) 2024/1689 (Artificial Intelligence Act), Art. 12 and Art. 14, 2024.
17. J. Pearl, Causality: Models, Reasoning, and Inference, 2nd ed., Cambridge Univ. Press, 2009.
18. F. Codevilla et al., "On Offline Evaluation of Vision-Based Driving Models," Proc. ECCV, 2018.