

博士研究計畫

史哲政 Zhe-Zheng Shi

題目：從可稽核紀錄到可驗證責任歸屬——學習致動系統的權限邊界形式化與稽核軌跡驗證

From Auditable Records to Verifiable Accountability: Formalising Authority Bounds and Verifying Audit Trails in Learning-Enabled Actuation Systems

一、研究背景與問題

基礎模型正在快速進入安全關鍵的致動迴路——自駕、機器人、工業控制、公共安全監控。監理端同步收緊：EU AI Act 將此類系統列為高風險，要求可追溯性與有效的人為監督。

但**部署速度遠快於稽核能力的建立**。目前的可解釋 AI 產出的是事後說法，不是可被第三方驗證的證據。當事故發生，一段模型產生的自然語言推理鏈，在監理機關或法庭面前無法承擔舉證責任——因為沒有人能證明那段文字就是當下真正驅動致動的東西。

我在碩士階段已經把問題推進了一步：提出嚴格梯度解耦的雙過程架構，讓語義推理模組能產出 GVQA 推理鏈作為稽核紀錄，並以語義-控制一致性 ($97.35 \pm 1.14\%$) 與因果影響 ($75.60 \pm 2.58\%$) 加以量化，同時證明開環閉環落差使離線指標不足以做部署決策。

但那些仍是**相關性證據**。這正是本計畫要跨越的門檻。

二、研究問題

可稽核紀錄要能承擔責任歸屬，必須同時滿足三個條件，目前無系統同時達成：

	條件	現況	本計畫對策
C1	完整性 ——無未記錄的致動旁路	未處理	資訊流分析 + 架構層強制
C2	不可否認性 ——紀錄不可竄改且可證明為當下所用	未處理	硬體信任根 + 承諾機制
C3	反事實可檢驗 ——可重放驗證因果	部分 (相關性)	確定性重放 + 反事實介入

核心研究問題：能否設計一種學習致動系統的架構與稽核協定，使得「模型推理對致動的影響」成為**可形式化驗證的性質**，而非統計上的觀察？

三、研究方法 (四階段，約四年)

階段一：權限邊界的形式化 (Y1)

把雙過程架構中的**有界權限**從工程設計提升為形式規格。

碩士階段的設計已經有雛形：System 1 在所有安全關鍵情境保有完整橫向控制權；System 2 只能降低速度目標，永遠不能提高。這其實是一組**安全不變量**。

工作內容：- 以時序邏輯 (如 STL / LTL) 表述權限不變量 - 證明架構在設計上使違反該不變量成為**不可能**，而非**不太可能** - 建立「規格內自由、規格外不可能」的設計模式，並論證其可移植性

為什麼重要：稽核對象因此從「模型行為」(不可窮舉) 轉為「規格是否被違反」(可判定)。

階段二：完整性——消除未記錄的致動旁路 (Y1-Y2)

C1 的難點在於證明**沒有遺漏**，而非找出已知路徑。

工作內容：- 對致動路徑做資訊流分析，識別所有能影響輸出的通道 - 設計架構層強制：任何未經稽核通道的訊號無法到達致動器 - 以故障注入驗證：刻意建立旁路，檢驗是否被偵測

階段三：不可否認的稽核軌跡 (Y2-Y3)

C2 需要密碼學而非機器學習。這裡可直接接上我的資安治理背景 (ISO 27001 LA)。

工作內容：- 稽核軌跡的承諾機制：對「感測輸入 + 推理輸出 + 致動指令」三元組做時序綁定 - 硬體信任根整合 (TPM / TEE) - 使紀錄產生於可信執行環境 - 效能預算評估——碩論的雙過程架構速度代價僅約 6%，稽核層必須維持同量級的可接受性

階段四：反事實驗證與跨域效度 (Y3-Y4)

C3 加上碩論明確留下的兩個缺口：跨域遷移未解、視覺紋理域偏移為僅存弱點。

工作內容：- 確定性重放框架：固定種子與環境版本，使閉環軌跡可重現 - 反事實介入：更換 System 2 輸出，量測致動是否真的隨之改變——從相關性推進到干預性證據 - 跨域評估：延續碩論的跨版本配對方法 (CARLA 0.10.0 與 0.9.15，150 組配對) - 擴展到不同模擬器與至少一個非自駕致動場域，檢驗設計原則的可移植性

四、預期貢獻

1. **理論**：學習致動系統中權限邊界的形式化框架，將 AI 模組權限從訓練期望轉為可驗證不變量
2. **方法**：可稽核性的三條件 (完整性 / 不可否認性 / 反事實可檢驗) 評估協定與對應指標
3. **系統**：具備可驗證稽核軌跡的閉環自駕原型，延續 Town10HD-Bench 基準
4. **治理**：對應 EU AI Act 高風險系統要求的技術落實路徑，可供監理與產業參考

五、可行性

- **已有基礎**：碩論與 IEEE Access / CACS 稿件已建立完整的閉環實驗平台、多種子評估流程 (n=5)、跨版本配對診斷方法與自建基準
- **跨域能力**：ISO 27001 Lead Auditor 與二十年安全關鍵系統交付經驗，使密碼學稽核層與監理對接不是紙上談兵
- **風險與備案**：階段三若硬體信任根整合受限於實驗設備，可退為軟體層承諾機制 + 形式化威脅模型分析，不影響 C1 與 C3 的推進

六、時程

年度	主要工作	預期產出
Y1	階段一、階段二前期	會議論文 ×1，形式化框架初稿
Y2	階段二完成、階段三	期刊論文 ×1
Y3	階段三完成、階段四前期	期刊論文 ×1，原型系統
Y4	階段四、整合、論文撰寫	期刊論文 ×1，博士論文