

博士班研究計畫

國立臺灣科技大學 資訊工程系 博士班 (116 學年度甄試) 申請人：史哲政

計畫名稱：具安全約束與致動追溯之多模態自主系統可稽核決策框架

An Auditable Decision Framework for Safety-Constrained Multimodal Autonomous Systems with Actuation Traceability

摘要

視覺語言模型等學習模組正逐步進入自動駕駛與機器人等安全關鍵之致動迴路，其推理紀錄常被視為事後稽核之依據，然而現有研究並未檢驗這些紀錄能否作為稽核證據。本計畫主張，一份稽核紀錄須同時滿足安全控制約束、致動完整性、證據完整性與反事實忠實性，方能承擔責任歸屬，並據此提出四項可被否認之研究假設：有界仲裁之權限可被形式化證明 (H1)、單一致動閘道可排除未記錄之致動旁路 (H2)、密碼學稽核層可在即時控制預算內運作 (H3)，以及紀錄所述理由僅部分對致動具可重現之反事實影響 (H4)。研究以 CARLA 閉環自駕模擬為第一個實驗場域，結合信號時序邏輯、SMT 求解、故障注入、雜湊鍵簽章與反事實重放等方法逐一檢驗，並延伸至非自駕場域檢驗其可移植性。預期成果為一套可稽核性評估協定與具備可驗證稽核軌跡之閉環原型。

研究主軸：本研究探討多模態 AI 參與安全關鍵閉環控制時，如何建立明確的權限邊界、可追溯的致動路徑與可信的決策證據，使模型的語義推理由「可解釋」進一步走向「可稽核」。自動駕駛與智慧交通為本研究之驗證場域；研究貢獻在於可推廣至其他安全關鍵閉環系統之形式化權限模型、致動完整性檢查與反事實忠實性驗證方法。

關鍵詞：可稽核人工智慧、學習致動系統、信號時序邏輯、防竄改紀錄、反事實忠實性、視覺語言模型

一、研究背景與動機

視覺語言模型 (Vision-Language Model, VLM) 與其他基礎模型正逐步進入自動駕駛、機器人與公共安全監控等安全關鍵之致動迴路。這類系統通常由學習模組提出判斷，再經由規則式之仲裁層決定最終致動，並將模型之推理內容記錄下來，作為事後稽核之依據。一旦系統判斷錯誤，監理機關、第三方稽核方與法院所需要的，並非事後補充之說明，而是可被獨立驗證之證據：這份推理紀錄，是否即為當下實際驅動控制之依據。

歐盟人工智慧法對高風險系統要求自動紀錄與人為監督 [1]，但法規只規定「要有紀錄」，並未規定紀錄須具備何種技術性質。現有研究多將模型產生之語言推理直接視為可解釋性之來源，卻未檢驗其能否作為稽核證據。從稽核實務之角度，一份紀錄若要承擔責任歸屬，至少須同時滿足四項條件：

- **安全控制約束：**學習模組之權限有明確邊界，且可被形式化規格描述與機器檢查；
- **致動完整性：**系統中沒有未被記錄之致動路徑，每次實際致動皆可追溯至已核准之指令；
- **證據完整性：**紀錄無法在事後被竄改、刪除、插入或重排而不被偵測，且可證明為當下所用；
- **反事實忠實性：**紀錄所述理由對致動具可重現之反事實影響，而非事後之合理化。

目前這四項條件分屬形式化安全、資訊安全與可解釋人工智慧三個研究脈絡，尚無研究在同一個即時控制系統中同時加以檢驗。本計畫之動機，即在於將「模型推理對致動之影響」由統計上之觀察，推進為可驗證之系統性質。

二、研究目的

本計畫之總目的為建立學習致動系統之可稽核性評估協定，使稽核紀錄得以承擔責任歸屬。具體目的如下：

1. 將學習模組之權限邊界描述為可機器檢查之規格，並檢驗其在學習模組之任意輸出下是否皆成立。
2. 在架構層面排除未被記錄之致動旁路，並提出可檢驗之完整性驗證方法。
3. 在即時控制預算內產生竄改可被偵測、且可證明為當下所用之稽核軌跡，並量化其成本與參數取舍。
4. 提出逐筆稽核紀錄之反事實忠實性量測方法，並檢驗其在自駕以外場域之適用性。

三、研究問題與假設

本計畫之核心研究問題為：**學習致動系統之稽核紀錄，能否被設計為在安全控制約束、致動完整性、證據完整性與反事實忠實性四方面皆可驗證？**據此以「一個最小可行的可稽核決策框架、四個模組」組織研究，每個模組對應一項可被實驗結果否證之研究假設：

- **H1 (模組 1 權限邊界建模)** 當學習模組僅能透過有界之仲裁規則影響致動時，其權限可被有限個信號時序邏輯規格完整表述，且在學習模組之任意輸出下皆成立；若改以加權融合，則存在可被搜尋出之違反反例。
- **H2 (模組 2 致動完整性檢查)** 以單一致動閘道強制所有致動指令經過稽核通道，可偵測所有植入之致動旁路，且不改變系統之閉環行為。
- **H3 (模組 3 防竄改稽核紀錄)** 雜湊鏈結合定期簽章之稽核層，其每週期額外延遲可低於控制週期之 10%；簽章間隔與可被否認之時間窗口之間存在可量化之取舍。
- **H4 (模組 4 反事實忠實性驗證)** 稽核紀錄所述理由中，只有一部分對致動具可重現之反事實影響；紀錄忠實率將顯著低於學習模組之介入頻率，且不同來源之推理具有不同之忠實率。

四、相關研究與研究定位

(一) 語言推理之自駕模型與解釋忠實性

DriveLM [2] 以圖視覺問答 (Graph Visual Question Answering, GVQA) 組織感知、預測與規劃之推理鏈，DriveVLM [3] 以視覺語言模型進行場景描述與分層規劃，LMDrive [4] 則以語言指令驅動閉環駕駛。這些研究皆將模型產生之語言推理視為可解釋性之來源。然而可解釋人工智慧之綜述指出，自駕領域之事後解釋多缺乏驗證機制 [5]。Jacovi 與 Goldberg [6] 區分解釋之「可信度」與「忠實性」，指出人類認為合理解釋不一定反映模型之實際決策過程；Turpin 等人 [7] 以實驗顯示，語言模型之推理鏈可能系統性地省略真正影響答案之因素；Lanham 等人 [8] 進一步以截斷與替換推理步驟之方式量測推理鏈之忠實性。這些研究皆在問答任務中進行，尚未延伸至連續控制之閉環系統，此即 H4 所要處理之處。

(二) 執行期保障與形式化安全

Simplex 架構 [9] 以簡單且可驗證之控制器監督複雜控制器，當複雜控制器之輸出可能違反安全條件時切換至安全控制器；安全遮蔽 (shielding) [10] 於強化學習中以形式化規格阻擋違反規格之動作；責任敏感安全模型 [11] 以形式化規則界定自駕車之安全行為。信號時序邏輯 (Signal Temporal Logic, STL) [12] 可描述連續訊號之時序性質，其穩健度語意 [13] 將「是否滿足規格」延伸為「距離違反規格有多遠」之連續量，並發展出以穩健度為目標之反例搜尋工具，如 S-TaLiRo [14]。SMT 求解器 [15] 則可對有限規模之邏輯進行窮舉驗證。Seshia 等人 [16] 指出，含學習模組之系統之驗證挑戰，在於學習模組本身難以形式化規格。本計畫之策略是不直接驗證學習模組，而是驗證學習模組「能影響什麼」，此為 H1、H2 之立足點。

(三) 防竄改紀錄與可信執行環境

Schneier 與 Kelsey [17] 提出以雜湊鏈與逐步演進之金鑰保護稽核日誌，使攻擊者即使取得系統控制權，也無法在不被偵測之情況下修改既有紀錄；Crosby 與 Wallach [18] 以 Merkle 樹 [19] 結構降低驗證成本，使驗證者不必讀取全部紀錄即可確認特定紀錄之完整性。Winfield 與 Jirotko [20] 主張機器人應如飛航紀錄器般保存事件紀錄。可信執行環境 (Trusted Execution Environment, TEE) 如 Intel SGX 與 ARM TrustZone [21], [22]，則可將簽章金鑰隔離於一般作業系統之外。然而上述研究多針對一般資訊系統，較少討論在毫秒級控制週期內之時間成本，也未將紀錄內容與致動指令綁定，此為 H3 所要量化之處。

(四) 本研究之定位

綜合上述文獻，三個研究脈絡各自解決問題之一部分：語言推理之自駕模型能產生人類可讀之理由，但無法保證其即為決策依據；執行期保障確保致動落在安全包絡內，但未界定語義推理之影響範圍；防竄改紀錄確保紀錄事後未被修改，但無法說明紀錄與致動之因果關係。本計畫之定位即在三者之交會處。

五、研究方法

(一) 研究架構與受測系統

受測系統採「學習模組提出建議、規則式仲裁層決定致動、稽核層記錄推理與指令」之三層架構 (圖 1)。第一個受測對象為碩士研究所建構之雙過程系統：System 1 為確定性幾何控制器，System 2 為視覺語言模型，兩者經由仲裁層 (融合橋) 耦合，且具備完整之內部訊號可供量測。實驗環境為 CARLA 閉環自駕模擬 [23]，因其同步模式可以固定隨機種子重現相同情境，便於進行配對比較與反事實重放。四項假設分別對應系統中之不同位置：H1 檢驗仲裁層，H2 檢驗仲裁層至致動器之路徑，H3 檢驗稽核軌跡之產生與保存，H4 檢驗推理至致動之因果鏈。




圖 1 研究架構：四個模組 (對應 H1-H4) 在受測系統中之位置

(二) 研究流程

本計畫依以下五個階段進行，前一階段之產出為後一階段之前提：

1. **規格化階段**：將仲裁規則表述為 STL 規格，建立控制軟體之資訊流圖，確立 H1、H2 之檢驗對象。

2. **權限與完整性驗證階段**：以 SMT 求解與反例搜尋檢驗 H1，以故障注入檢驗 H2，並依反例修正仲裁規則與致動閘道。
3. **稽核層實作階段**：在通過 H1、H2 之系統上實作雜湊鍵與簽章機制，檢驗 H3。
4. **反事實驗證階段**：在具備可信稽核軌跡之系統上建立可重現重放，檢驗 H4。
5. **跨域驗證與整合階段**：將上述設計移植至非自駕之致動場域重複檢驗，整合為可稽核性評估協定。

(三) 模組 1 權限邊界建模 (H1)

設計。將仲裁規則表述為 STL 規格，例如「任何時刻之速度指令不高於幾何控制器之速度目標」與「安全關鍵情境下之轉向指令等於幾何控制器之輸出」。自變項為融合方式，分為三組：有界仲裁（受測設計）、加權融合（將學習模組輸出以固定權重併入控制）與無限制融合（學習模組輸出直接覆寫）。依變項為規格違反次數與 STL 最小穩健度。

形式化定義。令時間 t 之系統狀態為 x_t ，幾何控制器 (System 1) 與學習模組 (System 2) 之輸出分別為 a_t^{S1} 與 a_t^{S2} 。由仲裁層 G 決定實際致動指令之結構，源自 Simplex 架構 [9] 與安全遮蔽 [10]：

$$a_t = G(a_t^{S1}, a_t^{S2}, x_t) \quad (1)$$

學習模組之權限以狀態相依之可容許集合 $\mathcal{A}_2(x_t)$ 定義，沿用安全遮蔽 [10] 與責任敏感安全模型 [11] 之定義方式，例如速度指令不得高於幾何控制器之速度目標：

$$a_t^{S2} \in \mathcal{A}_2(x_t), \quad v_t^{\text{cmd}} \leq v_t^{S1} \quad (2)$$

未經授權時，橫向控制不得偏離幾何控制器 ($\square$ 為時序邏輯之「恆成立」運算子 [12])：

$$\square(\neg \text{Auth}(S2, \delta_t) \rightarrow \delta_t^{\text{cmd}} = \delta_t^{S1}) \quad (3)$$

安全不變量要求系統狀態始終位於安全集合 $\mathcal{S}$ ，即安全集合之前向不變性 [24]；閉環中以規格 φ 之 STL 穩健度 ρ [13] 量測距離違反之裕度， ρ 小於 0 即為規格違反：

$$\square(x_t \in \mathcal{S}), \quad \rho(\varphi, x, t) \geq 0 \quad (4)$$

方法。分兩階段檢驗。離線階段以 SMT 求解器 [15]，對學習模組輸出之完整值域求解是否存在違反規格之輸入；若結果為不可滿足，即證明規格在任意輸出下成立。閉環階段以穩健度為目標函數，參考 S-TaLiRo [14] 之方法主動搜尋使穩健度最小之輸出序列，並對照隨機注入、對抗性注入與失效注入三種方式。

實驗規模。閉環階段涵蓋五條路線、五個隨機種子，三組融合方式各執行完整評估；反例搜尋之預算以每組每路線相同之模擬次數為上限，確保三組之比較公平。

判定。H1 成立之條件為：有界仲裁於離線階段無反例、閉環階段違反次數為零，且兩組對照皆能被搜尋出反例。若有界仲裁被找到反例，代表規則存在未涵蓋之情境，反例本身即可用於修正規則，修正後重新驗證。

(四) 模組 2 致動完整性檢查 (H2)

設計。建立控制軟體之資訊流圖，找出所有能影響致動器之通道，並設置單一致動閘道，僅接受已登錄於稽核軌跡之指令。自變項為旁路類型與有無閘道；旁路類型包含直接寫入車輛控制、繞過仲裁層與重放過期指令三類。依變項為旁路偵測率、正常運行下之誤報率，以及路線完成率與碰撞次數。

實驗規模。每類旁路於五條路線之不同決策時點各植入至少二十次，植入時點以隨機方式決定並事先記錄，使偵測率之估計具有足夠之樣本；正常運行則以五路線、五種子之完整評估量測誤報。

判定。有閘道組之植入旁路須全數被偵測，正常運行誤報為零；並以相同隨機種子配對比較有無閘道之閉環結果，確認閘道本身不改變系統行為。若有旁路未被偵測，則回到資訊流圖分析遺漏之通道。

(五) 模組 3 防竄改稽核紀錄 (H3)

設計。每個控制週期將感測影格雜湊值、學習模組推理輸出、仲裁後指令與時間戳組成一筆紀錄，以雜湊鏈串接，並定期對 Merkle 樹根簽章。自變項為簽章間隔（每週期、每 10 週期、每 30 週期）與金鑰保存位置（可信執行環境與軟體金鑰），共六種條件。依變項為每週期額外延遲之分布（含第 99 百分位數）、每小時儲存量、竄改偵測率與可被否認之時間窗口。

方法。以 30 Hz 控制週期（約 33.3 ms）為基準，每週期額外延遲上限為控制週期之 10%。竄改測試包含刪除、修改、插入與重排紀錄四類，每類於不同位置各執行多次。加入稽核層前後之閉環結果以相同種子配對，採 Wilcoxon 符號等級檢定比較路線完成率與行駛速度。

判定。竄改偵測率須為 100%，且至少一種條件之第 99 百分位延遲低於上限，閉環結果無顯著差異。預期產出簽章間隔對延遲與否認窗口之取捨曲線，作為實際部署時選擇參數之依據。

(六) 模組 4 反事實忠實性驗證 (H4)

設計。以固定隨機種子建立可重現之重放，於抽樣之決策時點進行三種干預 [25]：替換學習模組之輸出、遮蔽紀錄中所引用之場景要素（例如推理提及之行人），以及遮蔽紀錄中未引用之場景要素（作為對照）。依變項為干預前後之致動差異。

估計量。對紀錄理由所引用之場景元素 e 進行干預 $do(e \rightarrow e')$ [25]，比較干預前後致動指令之差異；其形式對應於干預下之直接效果 [26]：

$$\Delta_e = \mathbb{E} \left[\left| a_t^{\text{cmd}}(do(e \rightarrow e')) - a_t^{\text{cmd}} \right| \right] \quad (5)$$

其中期望值取自固定種子之重複重放； Δ_e 須超過未干預時之殘餘變異，方判定該理由對致動具反事實影響。

方法。先在不做任何干預之情況下重複重放，量化模擬本身之殘餘變異，作為判定基準。若遮蔽所引用之要素使致動改變超過殘餘變異，且遮蔽未引用之要素不造成改變，則判定該筆紀錄之理由對致動具反事實影響。紀錄忠實率定義為判定具反事實影響之紀錄比例，並依推理來源（即時推理與模板傳播）分別計算，以比例檢定比較兩者差異。

實驗規模。自五條路線、五個種子中，依場景類型（路口、跟車、行人、直行）分層抽樣決策時點，初估五百個以上，確保各類場景皆有足夠樣本。

判定與延伸。H4 預期忠實率顯著低於介入頻率；若結果相反，代表介入頻率低估了推理之必要性，同樣具有報告價值。完成自駕場域之檢驗後，以相同干預設計於至少一個非自駕之致動場域重複實驗，檢驗忠實率之差異是否來自場域特性。

(七) 評估指標總覽

假設	自變項	主要依變項	判定條件
模組 1 (H1)	融合方式 (三組)	規格違反次數、最小穩健度	有界仲裁無反例，對照組有反例
模組 2 (H2)	旁路類型、有無闌道	偵測率、誤報率、閉環結果	設計威脅模型下全數偵測、量測誤報、行為不變
模組 3 (H3)	簽章間隔、金鑰位置	延遲分布、儲存量、竄改偵測率	所設計竄改類型全數偵測、延遲不超過週期 10%
模組 4 (H4)	干預類型、推理來源	致動差異、紀錄忠實率	干預效應大於重放變異

(八) 實驗設計原則

離線指標無法代表系統在迴路中之行為 [27]，因此四項假設皆於閉環中檢驗。所有比較均以相同隨機種子配對進行，每個條件至少五個種子；判定條件與統計方法於實驗前訂定，不依結果調整；原始量測資料隨論文公開，以便他人重現與稽核。

(九) 研究範圍與限制

本計畫之研究對象為「學習模組經由規則式仲裁層影響致動」之系統，不以端到端直接輸出控制之模型為主要對象，因其缺乏本研究所假設之顯式仲裁介面與模組化權限分解，需採不同的驗證方法。H1 驗證的是仲裁層之性質，而非學習模組本身之正確性。實驗以模擬為主，模擬與實車之差距不在本計畫之驗證範圍內，但 H3 之延遲量測將於實體硬體上進行，以確保時間成本之結論具有實務意義。

六、研究設計之實例：碩士研究

上述設計方式來自我在碩士研究中之實際做法。碩士論文〈視覺語言模型在可稽核端到端自動駕駛系統之應用與評估〉之研究過程，可以說明我如何由現象提出假設，並設計實驗加以檢驗。

由現象到假設。研究初期觀察到，當視覺語言模型與連續控制器共用視覺編碼器時，轉向輸出會逐漸趨近於零。我提出之假設是：語言損失對共享參數之梯度壓力遠大於控制損失，使共享表徵偏向語義而失去幾何資訊。為檢驗此假設，我直接量測兩種損失對共享參數之梯度比，冷啟動實測為 35–41:1，並以車道邊界等空間稀疏線索之注意力權重，說明幾何資訊被壓抑之機制。

以對照實驗排除替代解釋。我設計八個架構變體進行比較，並同時量測開環與閉環結果。其中一個統一架構變體之開環轉向誤差 (MAE 0.0113) 優於不崩潰之架構 (0.0144)，閉環路線完成率卻僅 9%。這項結果否定了「開環誤差低即代表可用」之替代解釋，也使我將閉環驗證列為必要條件。

以可重現之閉環實驗驗證設計。依據上述假設，我提出嚴格梯度解耦之雙過程架構，並在五條路線、五個隨機種子之閉環評估中檢驗，達成完整路線完成與零碰撞；另以 CARLA 兩個版本共 150 場之配對閉環實驗，界定結果之適用範圍。

主動揭露指標之限制。論文報告之因果影響率為 $75.60 \pm 2.58\%$ ，但我進一步拆解其組成，發現其中 72.43 個百分點來自模板傳播，即時 VLM 推理僅占 1.69%，因此在論文中明確寫出此指標衡量的是介入頻率，而非反事實必要性。這項自我檢驗正是本計畫 H4 之由來：一個指標在報告之前，應先確認它量測的是否就是研究者宣稱之性質。

七、研究資源與設備

- **運算設備：**自有之 GPU 工作站 (NVIDIA RTX 5090，32 GB 記憶體)，可執行 CARLA 閉環模擬與視覺語言模型推論；以碩士階段之實測，單一種子完成五條路線之閉環評估約需 30 分鐘。

- **軟體工具**：CARLA 模擬器、SMT 求解器 (如 cvc5 [15])、STL 監控與反例搜尋工具，以及開源之密碼學函式庫，皆為公開可取得之工具。
- **可信執行環境**：H3 需要支援 TEE 之硬體平台；將依指導教授實驗室之既有設備選擇，若無合適設備，則以 ARM TrustZone 開發板等低成本平台進行，或採第八節所述之備案。

八、可能遭遇之困難與因應

可能困難	影響	因應方式
仲裁規則過於複雜，SMT 求解無法在合理時間內完成	H1 離線證明	將規則分解為獨立子規格分別驗證，或以有界模型檢驗限定時間範圍
模擬之殘餘變異過大，干預效應難以分辨	H4 判定	增加重放次數估計變異分布，並改以統計檢定判定干預效應
缺乏可用之 TEE 硬體	H3 金鑰位置因子	以軟體金鑰搭配外部時間戳進行，並以形式化威脅模型分析兩者差異
非自駕場域之實驗平台取得不易	H4 跨域延伸	依指導教授實驗室之既有平台選擇場域，或以開源機器人模擬器替代

九、研究倫理

本計畫之實驗皆於模擬環境與自有設備中進行，不涉及人體受試者與個人資料。實驗所用之模擬情境與原始量測資料將隨論文公開，研究過程遵循本校學術研究倫理規範。

十、預期成果與貢獻

學術貢獻。若 H1、H2 成立，學習模組之權限將由訓練期望轉為可證明之不變量，稽核對象由不可窮舉之模型行為轉為可判定之規格違反。H4 將以反事實必要性取代介入頻率，提出逐筆稽核紀錄之忠實性量測方法，將忠實性研究由問答任務延伸至閉環控制。

技術貢獻。H3 將提供密碼學稽核層在即時控制系統中之時間成本與參數取舍依據；本計畫亦將完成一套具備可驗證稽核軌跡之閉環原型，並公開其實作。

應用貢獻。本計畫提出之可稽核性評估協定，可作為高風險人工智慧系統落實紀錄與人為監督要求之技術路徑，供監理機關、第三方稽核單位與產業參考。

預期發表。會議論文一篇 (H1)，期刊或國際會議論文三篇 (H2 與 H3、H4、跨域驗證)，投稿方向包括智慧運輸、形式化方法與資訊安全領域之國際會議與期刊，以及博士論文一本。

十一、研究進度

本計畫以五年在職進修規劃 (圖 2)。依本系規定，資格考須於入學後二年內通過，因此資格考之基礎能力審定課程排在第一年，專業能力審定排在第二年。




圖 2 五年研究進度與預期產出

期間	研究工作	修業里程碑
第一年	規格化階段；H1 離線證明與閉環反例搜尋	基礎能力審定課程、學術研究倫理、論文研討（一）
第二年	H1 論文投稿；H2 故障注入實驗	通過資格考（基礎能力與專業能力審定）、論文研討（二）
第三年	H3 稽核層實作與延遲量測；完成原型系統	修畢 18 學分
第四年	H4 反事實重放與跨域實驗	期刊論文投稿
第五年	整合為可稽核性評估協定；撰寫博士論文	學位考試

十二、與本系研究環境之關聯

本計畫同時需要多模態推理系統、可信賴人工智慧與系統安全之研究環境。本系教師之研究領域涵蓋多模態與電腦視覺、可信賴人工智慧代理人、人工智慧安全、硬體信任根與可信任執行環境，以及機器學習，與本計畫四項假設之檢驗直接相關；H1 所需之时序邏輯與形式驗證訓練，則以臺灣大學系統跨校選修補足。本計畫以自動駕駛作為第一個驗證場域，後續之應用場域與各研究工作之權重，將依指導教授之研究重點與實驗室既有平台調整。

參考文獻

- [1] Regulation (EU) 2024/1689 of the European Parliament and of the Council Laying Down Harmonised Rules on Artificial Intelligence (Artificial Intelligence Act), Off. J. Eur. Union, Jul. 12, 2024, Arts. 12 and 14.
- [2] C. Sima et al., "DriveLM: Driving with graph visual question answering," in Proc. Eur. Conf. Comput. Vis. (ECCV), Milan, Italy, 2024, pp. 256–274.
- [3] X. Tian et al., "DriveVLM: The convergence of autonomous driving and large vision-language models," in Proc. Conf. Robot Learn. (CoRL), Munich, Germany, 2024, pp. 4698–4726.
- [4] H. Shao et al., "LMDrive: Closed-loop end-to-end driving with large language models," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Seattle, WA, USA, 2024, pp. 15120–15130.
- [5] S. Atakishiyev, M. Salameh, H. Yao, and R. Goebel, "Explainable artificial intelligence for autonomous driving: A comprehensive overview and field guide for future research directions," IEEE Access, vol. 12, pp. 101603–101625, 2024.
- [6] A. Jacovi and Y. Goldberg, "Towards faithfully interpretable NLP systems: How should we define and evaluate faithfulness?" in Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL), 2020, pp. 4198–4205.
- [7] M. Turpin, J. Michael, E. Perez, and S. R. Bowman, "Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting," in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS), vol. 36, 2023.

- [8] T. Lanham et al., “Measuring faithfulness in chain-of-thought reasoning,” 2023, arXiv:2307.13702.
- [9] D. Phan, J. Yang, M. Clark, R. Grosu, J. D. Schierman, S. A. Smolka, and S. D. Stoller, “A component-based simplex architecture for high-assurance cyber-physical systems,” in Proc. 17th Int. Conf. Appl. Concurrency Syst. Des. (ACSD), Zaragoza, Spain, 2017.
- [10] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, “Safe reinforcement learning via shielding,” in Proc. AAAI Conf. Artif. Intell., vol. 32, no. 1, 2018.
- [11] S. Shalev-Shwartz, S. Shammah, and A. Shashua, “On a formal model of safe and scalable self-driving cars,” 2017, arXiv:1708.06374.
- [12] O. Maler and D. Nickovic, “Monitoring temporal properties of continuous signals,” in Proc. Int. Symp. Formal Techn. Real-Time Fault-Tolerant Syst. (FORMATS/FTRTFT), Grenoble, France, 2004, pp. 152–166.
- [13] A. Donzé and O. Maler, “Robust satisfaction of temporal logic over real-valued signals,” in Proc. Int. Conf. Formal Model. Anal. Timed Syst. (FORMATS), Klosterneuburg, Austria, 2010, pp. 92–106.
- [14] Y. Annpureddy, C. Liu, G. Fainekos, and S. Sankaranarayanan, “S-TaLiRo: A tool for temporal logic falsification for hybrid systems,” in Proc. Int. Conf. Tools Algorithms Construct. Anal. Syst. (TACAS), Saarbrücken, Germany, 2011, pp. 254–257.
- [15] H. Barbosa et al., “cvc5: A versatile and industrial-strength SMT solver,” in Proc. Int. Conf. Tools Algorithms Construct. Anal. Syst. (TACAS), Munich, Germany, 2022, pp. 415–442.
- [16] S. A. Seshia, D. Sadigh, and S. S. Sastry, “Toward verified artificial intelligence,” Commun. ACM, vol. 65, no. 7, pp. 46–55, Jul. 2022.
- [17] B. Schneier and J. Kelsey, “Secure audit logs to support computer forensics,” ACM Trans. Inf. Syst. Secur., vol. 2, no. 2, pp. 159–176, May 1999.
- [18] S. A. Crosby and D. S. Wallach, “Efficient data structures for tamper-evident logging,” in Proc. 18th USENIX Secur. Symp., Montreal, QC, Canada, 2009, pp. 317–334.
- [19] R. C. Merkle, “A certified digital signature,” in Proc. Adv. Cryptol. (CRYPTO), Santa Barbara, CA, USA, 1989, pp. 218–238.
- [20] A. F. T. Winfield and M. Jirotko, “The case for an ethical black box,” in Proc. Towards Auton. Robot. Syst. (TAROS), Guildford, U.K., 2017, pp. 262–273.
- [21] M. Schneider, R. J. Masti, S. Shinde, S. Capkun, and R. Perez, “SoK: Hardware-supported trusted execution environments,” 2022, arXiv:2205.12742.
- [22] S. Pinto and N. Santos, “Demystifying Arm TrustZone: A comprehensive survey,” ACM Comput. Surv., vol. 51, no. 6, Art. no. 130, 2019.
- [23] A. Dosovitskiy, G. Ros, F. Codevilla, A. López, and V. Koltun, “CARLA: An open urban driving simulator,” in Proc. Conf. Robot Learn. (CoRL), Mountain View, CA, USA, 2017, pp. 1–16.
- [24] A. D. Ames, S. Coogan, M. Egerstedt, G. Notomista, K. Sreenath, and P. Tabuada, “Control barrier functions: Theory and applications,” in Proc. 18th Eur. Control Conf. (ECC), Naples, Italy, 2019, pp. 3420–3431.
- [25] J. Pearl, “Causal inference in statistics: An overview,” Stat. Surveys, vol. 3, pp. 96–146, 2009.
- [26] J. Pearl, “Direct and indirect effects,” in Proc. 17th Conf. Uncertainty Artif. Intell. (UAI), Seattle, WA, USA, 2001, pp. 411–420.
- [27] F. Codevilla, A. M. López, V. Koltun, and A. Dosovitskiy, “On offline evaluation of vision-based driving models,” in Proc. Eur. Conf. Comput. Vis. (ECCV), Munich, Germany, 2018, pp. 246–262.